नाम: ईशान वर्मा अनुक्रमांक: 21CS091

Q1. ओवरफिटिंग तब होती है जब मॉडल प्रशिक्षण डेटा को, उसके शोर (noise) सहित, रट लेता है। इससे training data पर accuracy बहुत अधिक होती है पर नए test data पर प्रदर्शन खराब होता है।

उपाय: (1) Dropout — प्रशिक्षण के दौरान कुछ न्यूरॉन्स को यादृच्छिक रूप से बंद कर दिया जाता है, जिससे नेटवर्क किसी एक न्यूरॉन पर निर्भर नहीं रहता। (2) Early stopping — जब validation loss बढ़ने लगे तब प्रशिक्षण रोक देते हैं।

Q2. हर token के embedding को तीन सीखे गए matrices Wq, Wk, Wv से गुणा करके query, key और value vectors बनाए जाते हैं। query और सभी keys का dot product (QK^T) attention scores देता है। इन scores को sqrt(dk) से भाग देकर softmax लगाया जाता है ताकि weights का योग 1 हो। अंत में values का weighted sum output होता है।

Scaling इसलिए ज़रूरी है क्योंकि बड़े dk पर dot products बहुत बड़े हो जाते हैं, softmax saturate हो जाता है और gradients लगभग शून्य हो जाते हैं।

Q3. Precision = TP/(TP+FP) = 40/50 = 0.8; Recall = TP/(TP+FN) = 40/60 = 0.67; F1 = 2PR/(P+R) = 0.73; Accuracy = (40+30)/100 = 0.7

Q4. GAN में generator और discriminator एक-दूसरे से प्रतिस्पर्धा (minimax game) करते हैं। Diffusion model में डेटा में धीरे-धीरे Gaussian noise जोड़ा जाता है और network उस noise को हटाना (denoise) सीखता है।

GAN का प्रशिक्षण अस्थिर होता है और mode collapse की समस्या होती है; diffusion का प्रशिक्षण स्थिर है और samples अधिक विविध होते हैं। GAN एक ही forward pass में तेज़ी से image बनाता है, जबकि diffusion को कई steps लगते हैं इसलिए यह धीमा है।

Q5. RAG में documents को chunks में बाँटकर उनके embeddings एक vector database में रखे जाते हैं। प्रश्न का embedding बनाकर सबसे मिलते-जुलते top-k chunks निकाले जाते हैं और उन्हें prompt में जोड़कर LLM उत्तर देता है।

विफलता 1: गलत या अप्रासंगिक chunks मिलना — hybrid search (BM25 + embeddings) और re-ranker से सुधारें। विफलता 2: LLM फिर भी hallucinate करे — उसे केवल दिए गए context से उत्तर देने और स्रोत बताने का निर्देश दें।